

# U-Net

MICCAI 2015

Convolutional Networks for Biomedical Image Segmentation

# U-Net ?

# Biomedical - Image Segmentation


## End-to-End

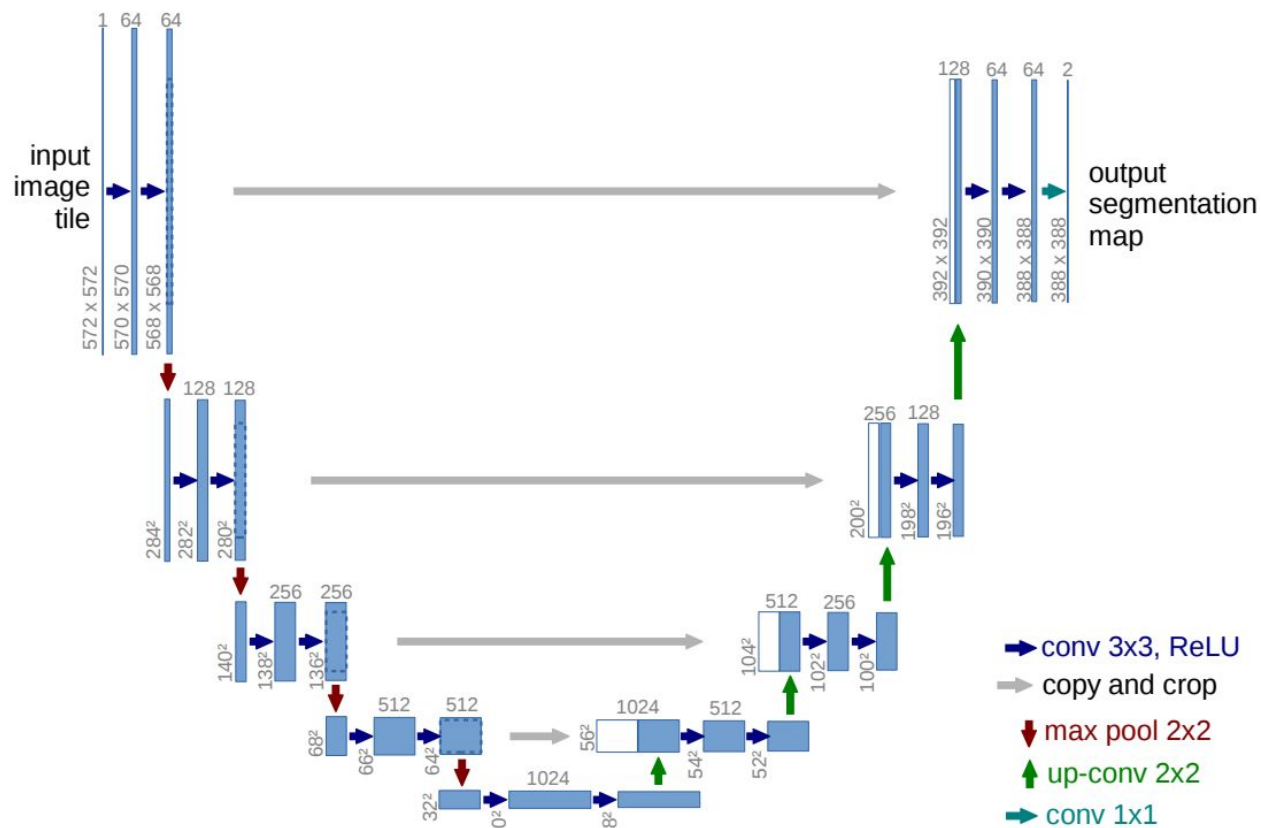
# Fully-Convolutional Network

## 레이블 정보가 있는 데이터가 적을 때 효율적인 data augmentation 기법을 제안

**확장 경로(expanding path):** 정밀한 지역화 (precise localization)가 가능하도록 합니다.

수축 경로(contracting path): 이미지에 존재하는 넓은 문맥(context) 정보를 처리합니다.







predict




Person  
Bicycle  
Background

# Contracting path

입력 이미지의 Context 포착 목적

FCNs 처럼 VGG-based Architecture




# Expanding Path

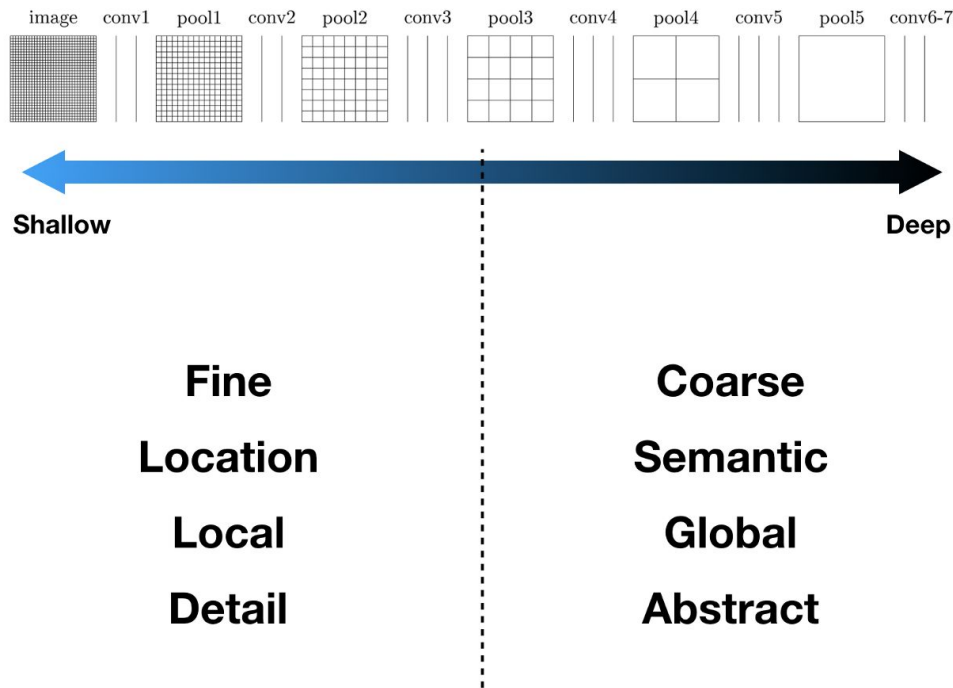
세밀한 Localization을 위해 구성

높은 차원의 채널을 갖는 Up-sampling

얇은 레이어의 feature map을 결합




FCN의 Skip Architecture  
개념을 활용하여 얇은 층의  
Feature map을 깊은 층의  
Feature map과 결합



# Architecture Detail



# Contracting Path



각 Contracting Step 마다 3x3 conv를 두 차례 반복

padding이 없으므로 feature map이 줄어듦

각 Contracting Step 마다  
2x2 max pooling (stride = 2) 연산  
feature map이 절반으로 줄어듦

Down-sampling 마다 채널의 수가 2배로 늘어남


# Expanding Path

마지막 레이어에 비선형 예측을 위한  
1x1 conv 연산


각 Expanding Path 마다  
2x2 up-conv 수행  
feature map의 크기가 2배로 늘어남

각 Expanding Path 마다  
3x3 conv를 두 차례 씩 반복  
padding이 없으므로 feature map이 줄어듦

Up-sampling 마다 채널의 수가  
절반으로 줄어듦




# Skip Architechure




각 Expanding Step 마다 up-conv 된 feature map은 contracting path의 cropped된 feature map과 concatenation

# Overlap-tile



Mirroring extrapolation



FCN 특성상 입력 이미지  
해상도에 제한이 없음

하지만 **UNet** 구조상 출력  
이미지의 해상도가 입력 이미지  
보다 작음

실제로 노란색 영역의  
**segmentation**이 필요하면  
**더 큰 파란색 영역의 패치**를  
삽입합니다.

이미지의 경계 부분은  
**extrapolation**을 사용합니다.

- **미러링(mirroring)** 활용

# Objective Function

$$p_k(x) = \frac{\exp(a_k(x))}{\sum_{k'=1}^K \exp(a_{k'}(x))}$$

pixel-wise

softmax

$x$ : 픽셀의 위치,  $k$ :  $k$  번째 특징 채널,  $a_k(x)$ :  $k$  번째 채널의  $x$  위치의 activation 값

$$E = \sum_{\mathbf{x} \in \Omega} w(\mathbf{x}) \log(p_{\ell(\mathbf{x})}(\mathbf{x}))$$

← 추가적인 가중치 함수 사용

$\ell(\mathbf{x})$ : 이미지의  $\mathbf{x}$ 의 true label

학습을 위해 cross-entropy 사용 (true label만 고려하므로, 일반 cross-entropy와 동일)

세포(cell)를 명확히 구분하기 위해 **작은 분리 경계(small separation border)**를 학습

명확한 분리를 위해  $w(\mathbf{x})$ 는 인접한 셀 사이에 있는 배경 레이블에 대하여 높은 가중치를 부여함

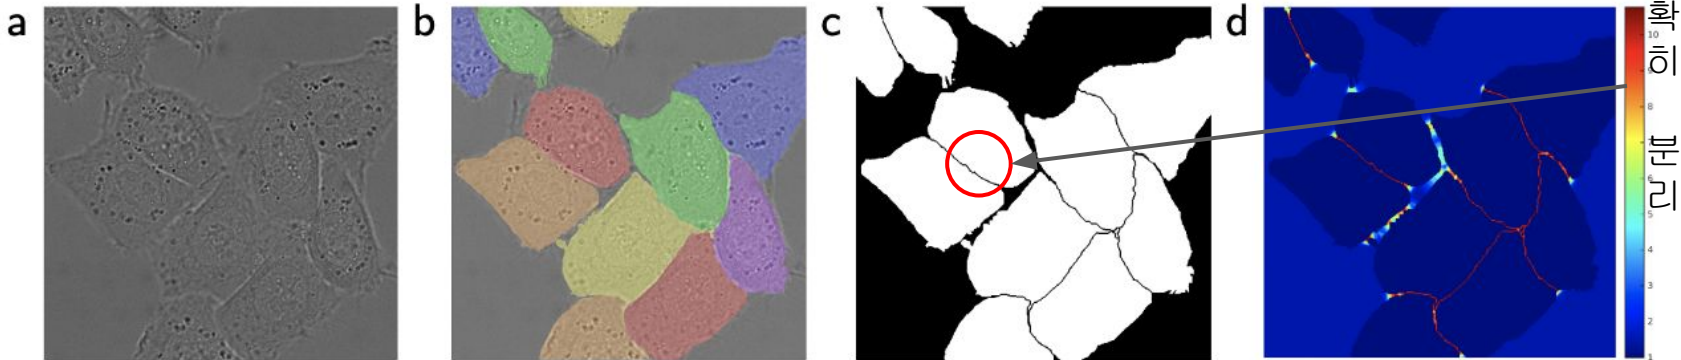
$$\underline{w(\mathbf{x})} = w_c(\mathbf{x}) + w_0 \cdot \exp \left( -\frac{(d_1(\mathbf{x}) + d_2(\mathbf{x}))^2}{2\sigma^2} \right)$$


세포와의 거리가 가까울수록 가중치 증가

$w_c: \Omega \rightarrow R$ : The weight map to balance the class frequencies.

$d_1: \Omega \rightarrow R$ : The distance to the border of the nearest cell.

$d_2: \Omega \rightarrow R$ : The distance to the border of the second nearest cell.





의료 데이터는 학습 데이터의 수가 적은 경우가 많아서, **data augmentation**이 필요


일반적인 data augmentation 기술과, Elastic Deformation 방법을 사용함

Rank	Group name	Warping Error	Rand Error	Pixel Error
	** human values **	0.000005	0.0021	0.0010
1.	u-net	<b>0.000353</b>	0.0382	0.0611
2.	DIVE-SCI	0.000355	0.0305	0.0584
3.	IDSIA [1]	0.000420	0.0504	0.0613
4.	DIVE	0.000430	0.0545	<b>0.0582</b>
⋮				
10.	IDSIA-SCI	0.000653	<b>0.0189</b>	0.1027

Electron Microscopy 대회의 데이터 셋으로 평가했을때 우수한 정확도



노란색 영역이 정답 label  
색칠된 영역이 모델의 예측결과



**Fig. 4.** Result on the ISBI cell tracking challenge. (a) part of an input image of the “PhC-U373” data set. (b) Segmentation result (cyan mask) with manual ground truth (yellow border) (c) input image of the “DIC-HeLa” data set. (d) Segmentation result (random colored masks) with manual ground truth (yellow border).

Name	PhC-U373	DIC-HeLa
IMCB-SG (2014)	0.2669	0.2935
KTH-SE (2014)	0.7953	0.4607
HOUS-US (2014)	0.5323	-
second-best 2015	0.83	0.46
u-net (2015)	<b>0.9203</b>	<b>0.7756</b>

PhC-U373, DIC-HeLa 두 데이터 셋에 대해 이전 보다 높은 IOU를 보임

U-Net은 FCNs보다 확장된 개념의 Up-sampling과 Skip Architecture를  
적용한 모델을 제안

결과적으로 U-Net의 구조는 아주 적은 양의 학습 데이터만으로 Data  
Augmentation을 활용하여 여러 Biomedical Image Segmentation  
문제에서 우수한 성능을 보여줌

감사합니다